

离散与连续环境下的智能体决策系统：基于 DQN 与行为树的坦克 AI 研究

黄鹤翔 高恒斌 都奕宁

信息与电子工程学院

浙江大学, 杭州, 中国

摘要—本报告详细阐述了一个基于深度强化学习 (DQN) 与启发式决策的迷宫自动寻路及对战 AI 系统的设计与实现。项目的核心挑战在于不依赖现有的深度学习框架, 而是仅使用 NumPy 库从底层构建卷积神经网络及优化器。报告首先介绍了迷宫生成算法 (DFS、Prim) 及经典启发式寻路算法 (A*), 随后深入探讨了自定义深度学习框架 simple_nn 的实现细节, 包括 im2col 卷积加速、反向传播算法及 Adam 优化器。在此基础上, 搭建了 DQN 模型, 设计了包含墙壁信息、位置信息及访问记录的 7 通道状态空间, 并通过经验回放和目标网络机制稳定训练过程。同时, 探索了基于遗传算法的神经网络进化策略, 通过锦标赛选择与精英保留机制优化智能体决策。此外, 针对连续物理环境下的复杂对战需求, 设计了基于分层行为树的智能决策系统。该系统引入了基于 Liang-Barsky 算法的通视性与危险势场分析、结合“拉线法”的混合路径规划及动态规避策略, 有效解决了连续空间下的碰撞检测与精准操控难题。最后, 展示了 AI 在迷宫寻路测试及人机对战模式中的表现, 验证了手写框架及决策树 AI 算法的有效性。

Index Terms—深度强化学习, DQN, 卷积神经网络, NumPy, 迷宫生成, A* 算法, 自动寻路, 启发式决策, 行为树, 混合路径规划, 危险势场

I. 引言

项目的设计灵感源于 B 站 up 河南胡季果和 L_Shy_P 的视频, 视频中出现了一个近乎无敌的 AI, 能够追踪敌人躲避子弹。

本项目旨在构建一个具备自主学习能力的坦克对战 AI 系统。与常规项目不同, 本项目的核心要求是“去框架化”, 即不调用成熟的深度学习库, 而是利用 Python 和 NumPy 从零实现神经网络的底层算子及训练机制。同时, 本项目还尝试了遗传算法 (Genetic Algorithm) 作为另一种优化手段, 通过模拟生物进化过程来迭代神经网络参数。这不仅考验对强化学习算法

的理解, 更要求对神经网络反向传播、矩阵运算及优化算法有深入的掌握。

此外, 为了应对更加复杂的连续物理环境对战需求, 本项目还设计了一套基于启发式规则与行为树的智能决策系统。传统的 DQN 模型虽然在离散网格中表现优异, 但在处理连续坐标、任意角度旋转及精细碰撞检测时面临状态空间爆炸的问题。因此, 本项目引入了“Smart AI”架构, 不再依赖强化学习, 而是结合了危险势场分析、混合路径规划及动态规避算法。这种启发式决策的设计, 旨在全面探索不同技术路线在游戏 AI 中的应用潜力, 既实现了离散环境下的端到端学习, 又保证了连续环境下的高水平竞技表现。

II. 设计任务和要求

本项目的具体设计任务和要求如下, 涵盖了从底层框架到上层决策的全栈开发:

1) 迷宫环境构建:

- 实现基于深度优先搜索和随机 Prim 算法的迷宫生成器, 支持生成不同拓扑结构的地图。
- 实现 A* 启发式寻路算法, 作为 AI 路径规划的基准。

2) 底层深度学习框架实现:

- 仅使用 NumPy 库, 从零构建神经网络核心算子, 包括全连接层、卷积层及激活函数。
- 实现 im2col 技术以加速卷积运算, 并推导实现各层的反向传播梯度计算。
- 实现 Adam 自适应优化器及 MSE Loss 损失函数, 支持网络的参数更新。

3) 离散环境强化学习 AI:

- 构建基于 CNN 的 Q 值估计网络，设计包含墙壁、位置及轨迹信息的 7 通道状态空间。
- 实现经验回放与目标网络机制，解决训练不稳定的问题。
- 在离散网格环境中训练智能体，实现从随机探索到最优路径规划的自主学习。

4) 遗传算法进化策略：

- 构建全连接神经网络作为决策模型，探索非梯度下降类的优化方法。
- 实现基于锦标赛选择、均匀交叉和高斯变异的遗传算法，用于神经网络参数的进化迭代。

5) 连续环境物理引擎适配：

- 升级游戏引擎以支持浮点坐标与任意角度旋转。
- 实现基于分离轴定理或 Liang-Barsky 算法的射线-OBV 碰撞检测，用于子弹判定与视线分析。

6) 连续环境启发式智能 AI：

- **危险感知：**设计危险评分模型，基于物理预测计算未来时间窗口内的碰撞风险。
- **决策系统：**构建分层行为树，实现生存优先、动态规避、战术进攻与路径巡逻的状态切换。
- **运动控制：**设计“网格 BFS + String Pulling 拉线法”的混合路径规划算法，并实现基于 PID 思想的平滑路径跟踪控制。

7) 人机对战系统集成：集成上述模型，实现流畅的实时对战功能，并提供 AI 决策的可视化调试。

- 递归完成后，整个网格形成一棵生成树，对应一个无环连通迷宫。

B. 迷宫生成算法-prim

Prim 算法原本用于求解最小生成树。在迷宫生成中，我们将其改造为随机 Prim 算法：不考虑边权，而是随机选择待扩展的边。

算法维护一个“边界集合”，包含所有与已生成区域相邻但尚未加入的格子。每一步从边界集中随机选取一个格子，将其与已生成区域中的某个邻居连接（打通墙壁），并将该格子的新邻居加入边界集。重复此过程直至覆盖全部格子。

- 将网格视为完全图，每条潜在通道（相邻格子间）是一条边；
- 任选一个起始格子加入生成树；
- 将其所有相邻格子加入“边界集”；
- 从边界集中随机选一格子，随机选择其一个已在生成树中的邻居，打通两者之间的墙，并将该格子纳入生成树，同时将其未访问邻居加入边界集；
- 直至所有格子被纳入。

III. 算法原理

A. 迷宫生成算法-DFS

DFS 迷宫生成算法本质上是一种递归回溯过程。它从起始格子出发，随机选择一个未访问的相邻格子进行“打通”（移除中间墙壁），然后递归地对该新格子执行相同操作。当当前格子的所有邻居均已被访问时，算法回退至上一层，直至遍历完整个网格。

- 将每个网格单元视为图中的一个节点；
- 初始时所有节点标记为“未访问”，所有相邻节点间存在“墙”；
- 从任意起点（如左上角 (0,0)）开始 DFS 遍历；
- 每次移动到新节点时，移除当前节点与目标节点之间的墙，并将目标节点加入连通图；

DFS 生成的迷宫通常具有长而曲折的走廊和较少的分支，Prim 生成的迷宫通常具有更多短分支和较短的主路径。




图 1: DFS 生成迷宫




图 2: prim 生成迷宫

C. 解迷宫算法-A*

A* 算法是一种广泛应用于路径规划和图遍历的启发式搜索算法。它结合了 Dijkstra 算法的完备性与贪心最佳优先搜索的效率，能够高效地找到从起点到终点的最短路径。

A* 算法通过评估函数 $f(n)$ 来决定下一个要探索的节点：

$$f(n) = g(n) + h(n)$$

其中：

- $g(n)$: 从起点到当前节点 n 的实际代价。
- $h(n)$: 从当前节点 n 到目标点的启发式估计代价。

在本项目中使用曼哈顿距离 $abs(x_1 - x_2) + abs(y_1 - y_2)$ 进行启发式搜索。我们在初始化时将起点 (0,0) 加入 open 列表中，然后进入循环，直到 open 列表为空或找到终点为止。在每一步迭代中，我们从 open 列表中选择 f 值最小的节点作为当前节点。然后检查当前节点是否为目标节点，如果是则结束循环；如果不是目标节点，则将其标记为已处理并将其相邻的未处理节点加入 open 列表中。同时，将已处理的节点加入 closed 列表中以避免重复处理。




图 3: A* 算法解迷宫

D. 自定义深度学习框架 (simple_nn)

为了替代 PyTorch，我们实现了 `simple_nn.py`。

1) 卷积层实现：卷积操作的核心在于高效地提取局部特征。为了避免低效的多重循环，采用了 `im2col` 技术，将输入特征图展开为矩阵，从而将卷积运算转化为矩阵乘法。

$$Y = W_{col} \times X_{col} + b \quad (1)$$

其中 X_{col} 是展开后的输入矩阵， W_{col} 是重排后的权重矩阵。

2) 优化器：实现了 Adam 优化器，结合了动量法和 RMSProp 的优点，自适应调整学习率。

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (3)$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t + \epsilon}} \hat{m}_t \quad (4)$$

E. AI 训练-DQN

DQN (Deep Q-Network) 将卷积神经网络与 Q-Learning 结合，解决了高维状态空间的强化学习问题。

1) 核心机制：

- 经验回放：构建一个回放池 D ，存储转移样本 $(s, a, r, s', done)$ 。训练时随机采样一个小批量，打破了数据间的相关性，提高了训练的稳定性。
- 目标网络：引入一个参数滞后的目标网络 \hat{Q} 计算目标值，避免了“自举”导致的目标值震荡。目标网络每一定时间从策略网络中复制参数。

通过贝尔曼最优方程来计算期望 Q 值，即执行该动作后获得的即时奖励 r 加上对未来最大 Q 值的折扣期望

$$Q^*(s, a) = \mathbf{E}_{s' \sim \mathcal{P}} [r + \gamma \max_{a'} Q^*(s', a')]$$

目标函数为最小化均方误差：

$$L(\theta) = \mathbf{E} \left[\left(r + \gamma \max_{a'} \hat{Q}(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (5)$$




图 4: dqn 算法流程结构

2) Q 值估计网络设计-输入层: 输入层设计为 $7 \times H \times W$ 的张量, 包含 7 个通道:

- 通道 0-3 (墙壁信息): 分别编码每个格子上、下、左、右四个方向的墙壁存在情况
- 通道 4-5 (位置信息): 分别使用 One-hot 编码智能体位置和目标位置
- 通道 6 (历史轨迹): 记录智能体访问过的路径, 赋予智能体记忆

3) Q 值估计网络设计-卷积层: 网络包含 4 层卷积层, 通道数分别为 32, 64, 128, 128, 主要为卷积层与 relu 激活层的循环。网络中没有加入传统 CNN 网络中常见的池化层, 主要是因为池化层的加入会模糊智能体与目标点的位置信息, 影响训练效果。

通过堆叠 4 层卷积层, 深层神经元的感受野逐渐扩大, 能够感知更大范围的迷宫结构, 从而规划长距离路径。通道数逐层增加 ($32 \rightarrow 128$), 使得网络能够组合低级几何特征。

表 I: 卷积神经网络各层参数配置

	输入通道数	输出通道数	卷积核大小	步长	填充
第一层	7	32	3	1	1
第二层	32	64	3	1	1
第三层	64	128	3	1	1
第四层	128	128	3	1	1

4) Q 值估计网络设计-全连接层: 卷积层输出展平后, 连接 3 层全连接层 ($1024 \rightarrow 512 \rightarrow 4$), 提供了强大的非线性拟合能力, 将提取的迷宫特征转化为上、下、左、右四个离散动作的 Q 值。

F. 超参数设计

```

1 # Hyperparameters
2 WIDTH, HEIGHT = 10, 10
3 EPISODES = 10000
4 BATCH_SIZE = 32
5 GAMMA = 0.9 # 对未来奖励的关心程度, 越大越关心
6 # 使用线性下降的 EPSILON, EPSILON 越大越倾向于随
  机探索
7 EPSILON_START = 1.0
8 EPSILON_END = 0.05
9 EPSILON_DECAY_EPISODES = 4000
10 LR = 0.0001
11 TARGET_UPDATE = 200 # 目标网络的更新频率
12 MEMORY_SIZE = 50000 # 经验池的大小

```

G. AI 训练-遗传算法

遗传算法是一种受达尔文生物进化论启发的元启发式优化算法。它模拟了自然界“物竞天择, 适者生存”的过程, 通过在解空间中维护一个种群 (Population), 并利用选择 (Selection)、交叉 (Crossover) 和变异 (Mutation) 等遗传算子, 迭代地演化出越来越优的解决方案。

在这个项目中, 我们使用一个全连接神经网络来对智能体的下一步动作进行决策, 通过遗传算法迭代更新神经网络的参数。同时在训练过程中, 我们借鉴了 DQN 的训练思路, 每隔一段时间将训练目标的参数从智能体中复制下来, 以求获得更加强大的智能体。

- 选择算子: 锦标赛选择
- 交叉算子: 均匀交叉
- 变异算子: 高斯扰动
- 进化策略: 精英保留, 将每一代中适应度最高的前 10% 个体 (精英) 直接复制到下一代, 不经过交叉和变异

H. 连续环境下的智能决策系统

随着游戏环境从离散网格升级为连续物理环境, AI 的决策机制也进行了相应的升级。新的智能体不再局限于上下左右的离散移动, 而是基于连续的坐标体系和角度控制, 实现了更加精准的战术动作。

1) 基于物理场的危险感知模型: 在连续环境中, 子弹的轨迹不再是简单的网格跳跃, 而是具有精确坐标和速度矢量的连续运动。AI 引入了危险评分机制, 通过模拟场上所有子弹在未来时间窗口 $T_w = 1.5s$ 内的运动轨迹, 计算其与自身碰撞的风险。

对于每一个子弹 b_i , 我们首先将其相对速度 v_{rel} 和相对位置投影到坦克的局部坐标系中。利用 Liang-Barsky 算法或分离轴定理, 检测子弹轨迹射线与坦克有向包围盒的相交情况。为了增加安全性, 我们在 OBB 检测中引入了安全边距 $margin = 5$ 像素。若发生碰撞, 则计算预计碰撞时间 t_{impact} 。危险分数 S_{danger} 定义为所有威胁子弹分数的最大值:

$$S_{danger} = \max_{i \in \mathcal{B}_{threat}} \left(\frac{1}{t_{impact}^{(i)} + \epsilon} \right) \quad (6)$$

其中 \mathcal{B}_{threat} 为所有在 T_w 内会发生碰撞的子弹集合, $\epsilon = 0.1$ 为防止除零的平滑项。该公式表明, 碰撞时间越短, 危险分数越高, 呈反比关系。

2) 分层行为树与动态规避：为了在复杂的实时对战中做出最优反应，AI 采用了基于优先级的行为树决策逻辑。系统在每一帧计算当前状态的危险分数，并据此动态切换行为模式：

- 1) **生存优先**：当检测到 $S_{danger} > 0$ 或预判动作会导致危险时，触发规避逻辑。系统采样动作空间 $\mathcal{A} = \{Forward, Backward, Stop\} \times \{Left, Right, None\}$ 中的 9 种候选动作，分别模拟执行后的未来状态并计算危险分数，选择 S_{danger} 最小的动作执行：

$$a^* = \arg \min_{a \in \mathcal{A}} S_{danger}(s', a) \quad (7)$$

- 2) **攻击决策**：若处于安全状态且满足射击条件，则进入攻击模式。系统计算目标方位角 θ_{target} 与当前朝向 $\theta_{current}$ 的偏差 $\Delta\theta$ ，采用比例控制策略调整朝向：

$$u_{turn} = \begin{cases} Right, & \text{if } \Delta\theta > \delta \\ Left, & \text{if } \Delta\theta < -\delta \\ None, & \text{otherwise} \end{cases} \quad (8)$$

其中 $\delta = 0.1$ rad 为瞄准死区。当 $|\Delta\theta| < 0.15$ rad 时，AI 将判定为锁定目标并自动开火。

- 3) **路径规划**：作为默认行为，规划通向敌人的路径。在路径跟踪控制中，我们采用了分段控制策略：

$$u_{move} = \begin{cases} Turn, & \text{if } |\Delta\theta| > 0.5 \text{ rad} \\ Forward + Turn, & \text{if } |\Delta\theta| \leq 0.5 \text{ rad} \end{cases} \quad (9)$$

该策略保证了在大幅度转向时原地旋转以避免碰撞，而在小角度偏差时能够边走边转，实现平滑的切向移动。

3) 视线检测与通视性分析：为了判断能否攻击敌人或进行路径平滑，系统实现了基于几何的通视性检测算法。该算法将连接起点与终点的线段视为射线，遍历场景中所有的静态墙壁和动态墙壁。

对于每一个墙壁矩形，将其适度膨胀以预留安全边距，然后利用 Liang-Barsky 线段裁剪算法检测射线是否与矩形相交。若无任何相交，则判定两点间通视。该检测被广泛应用于攻击判定和路径优化中。

4) 混合路径规划算法：针对连续环境下的移动需求，设计了“Dijkstra 全局规划 + 路径平滑”的混合路径规划算法：

- **全局规划**：在底层的网格地图上运行 Dijkstra 算法。由于网格图边权均等，该算法等价于广度优先搜索，能够保证找到从起点格子到终点格子的最短离散路径 $P_{grid} = \{c_0, c_1, \dots, c_n\}$ 。
- **路径平滑**：由于网格路径呈锯齿状，不符合坦克的运动学特性。系统采用“拉线法”对路径进行后处理：从路径起点 p_{start} 开始，贪心地尝试连接后续节点 p_k 。若线段 $\overline{p_{start}p_k}$ 不与任何墙壁相交，则剔除中间节点，将路径拉直。
- **路径跟踪控制**：智能体实时跟踪平滑后的路径点。控制律设计如下：若角度偏差 $|\Delta\theta| > 0.5$ rad，则原地旋转；若 $|\Delta\theta| \leq 0.5$ rad，则在调整角度的同时全速前进，实现平滑的切向移动。

连续环境下整体场景如下图所示：

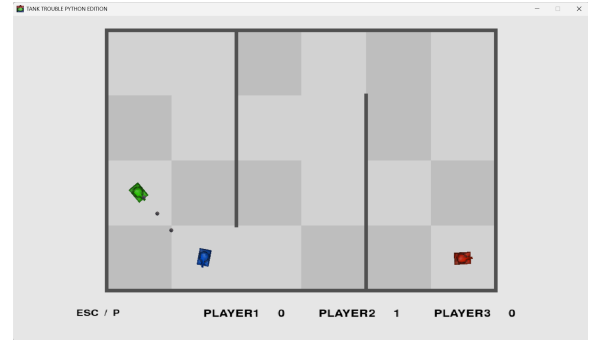


图 5: 连续环境下的坦克对战场景

IV. 主要仪器设备

- **开发语言**：Python 3.10
- **核心库**：NumPy (用于矩阵运算), Matplotlib (用于可视化)
- **硬件环境**：AMD CPU
- **操作系统**：Linux/Windows

V. 设计结果

对于简单环境的 DQN 训练，reward 曲线如下图所示




图 6: dqn 奖励变换曲线

更多结果请参见代码压缩包与视频压缩包

VI. 结论

本报告详细阐述了从零构建深度强化学习框架及坦克对战 AI 的全过程。我们首先成功实现了基于 NumPy 的底层神经网络框架，并通过 DQN 算法在离散迷宫中完成了初步的寻路训练，验证了“去框架化”深度学习的可行性。

同时，遗传算法的实验结果表明，在特定任务下，基于进化的参数搜索策略也能取得与梯度下降相媲美的效果，为强化学习提供了有益的补充。

随后，针对实战中复杂的连续物理环境，我们突破了离散动作空间的限制，开发了基于行为树、危险势场及混合路径规划的 Smart AI。该系统成功解决了连续空间下的碰撞检测、动态规避及平滑控制等难题。实验结果表明，Smart AI 在动态规避子弹和战术进攻方面表现优异，展现了启发式算法在实时对抗类游戏中的鲁棒性与高效性。

本项目不仅加深了对深度学习底层原理的理解，也探索了将传统游戏 AI 技术与现代物理引擎结合的有效路径，为后续研究更复杂的强化学习算法奠定了坚实基础。

VII. 参考文献

- 1) Mnih, V., Kavukcuoglu, K., Silver, D. et al. Human-level control through deep reinforcement learning. *Nature* 518, 529–533 (2015).
- 2) Hart, P. E., Nilsson, N. J., & Raphael, B. (1968). A Formal Basis for the Heuristic Determination of Minimum Cost Paths. *IEEE Transactions on Systems Science and Cybernetics*, 4(2), 100-107.

- 3) Liang, Y. D., & Barsky, B. A. (1984). A new concept and method for Line Clipping. *ACM Transactions on Graphics (TOG)*, 3(1), 1-22.
- 4) Holland, J. H. (1992). *Adaptation in natural and artificial systems*. MIT press.
- 5) 河南胡季果, L_Shy_P. (2024). Bilibili Video: <https://www.bilibili.com/video/BV17EswzLEKw/>

VIII. 项目代码

本项目的完整实现代码、训练脚本已开源在 GitHub 仓库: <https://github.com/GgbNnD/tankalg>

IX. 引用

连续环境下游戏引擎参考自 GitHub 开源项目: <https://github.com/mglyn/TANKTROUBLE-pythonedition.git>, 其依赖于 numpy/pygame 库